Auto-évaluation

Renforcez vos fondamentaux de Python pour la Data Science en analysant les données de systèmes éducatifs

Exercice en 3 parties - Analysez des données de systèmes éducatifs



Un dernier doute ?

Pour vérifier la qualité de votre travail :

- cochez les cases ci-dessous : elles indiquent que vous avez bien pris en compte chaque indicateur de réussite ;
- complétez votre fiche au fur et à mesure de votre progression dans votre exercice.
- renseignez, si besoin, la colonne “Notes” avec des commentaires sur vos livrables / vos étapes. Ils seront des points de discussion avec votre mentor pendant votre session de bilan / soutenance.

Quand toutes les cases de ce document seront cochées, vous pourrez déposer vos livrables sur la plateforme.

Bonne réussite !

Compétences	Indicateurs de réussite de l’activité	Notes
Exercice - Partie 1		
Appliquer des analyses statistiques descriptives et / ou naviguer visuellement au sein des données afin de	✔ J’ai vérifié que l’installation de JupyterLab (ou un équivalent) était fonctionnelle. ✔ J’ai importé Pandas, Matplotib et Seaborn sans erreur au sein du Notebook. ✔ Je suis capable d’expliquer ce que représente chaque ligne dans chaque jeu de données. ✔ J’ai calculé la taille des jeux de données avec Pandas.	J'utilise Google Colab, l'environnement Imports effectués sans erreur dans la c

détecter des anomalies.	✔ J'ai décrit le contenu des colonnes de chaque jeu de données en utilisant les méthodes fournies par Pandas.	Utilisation de describe() (stats) et info() (t
Supprimer / corriger les anomalies manuellement et à l'aide d'outils / logiciels de nettoyage des données adaptés.	✔ J'ai calculé le nombre de doublons avec Pandas et les ai supprimés. ✔ J'ai quantifié les valeurs manquantes par colonne dans les jeux de données. ✔ Mon traitement des valeurs manquantes est en cohérence avec la problématique métier. ✔ J'ai utilisé les filtrages à base de conditions de Pandas : ✔ pour supprimer les faux pays ; ✔ pour réduire le nombre d'indicateurs via une colonne contenant des catégories d'indicateurs. ✔ Ma matrice de corrélation est cohérente : ✔ elle a été calculée avec Pandas ; ✔ visualisée avec Seaborn ; ✔ utilisée pour filtrer les indicateurs redondants. ✔ Je suis capable d'expliquer le sens des coefficients de corrélation de Pearson et de Spearman. ✔ Je suis satisfait de l'utilisation des markdown.	Visualisation précise via Heatmap (Seab
Exercice - Partie 2		
Appliquer des analyses statistiques descriptives et /	✔ J'ai utilisé la méthode group_by() de Pandas pour évaluer la qualité des indicateurs et des années (en termes de valeurs renseignées).	J'ai utilisé pivot_table (qui est une abstra

ou naviguer visuellement au sein des données afin de détecter des anomalies.	✔ J'ai utilisé la méthode pivot_table() pour créer un jeu de données avec : ✔ comme lignes : des pays ; ✔ comme colonne : des indicateurs ; ✔ comme valeurs : des résultats d'agrégations d'années.	Transformation du format Long (Lignes)
	✔ Je suis satisfait de mon interprétation des résultats de la méthode describe() de Pandas. ✔ J'ai rendu visuelles et interprété les distributions d'une variable quantitative en utilisant Seaborn ou Matplotlib.	L'analyse des quartiles a permis de dét
	✔ J'ai nommé mes variables en respect des bonnes pratiques. ✔ J'ai implémenté au moins une fonction pour automatiser un traitement présent plusieurs fois dans le code. ✔ J'ai utilisé au moins une boucle for pour éviter de répéter manuellement un traitement/une analyse.	Noms explicites et en anglais (df_clean,
Exercice - Partie 3		
Configurer l'environnement de travail nécessaire à l'exploitation des données	✔ J'ai installé Poetry. ✔ J'ai créé et rempli un fichier pyproject.toml en utilisant poetry init et/ou poetry add. ✔ Le code de mon Notebook fonctionne correctement au sein de l'environnement virtuel que j'ai créé.	Installation automatisée via script (os.sy

Présenter ses résultats	✔ Je suis satisfait de mon rappel du contexte métier au centre de toutes les analyses. ✔ Je présente de manière précise le contenu de chaque fichier de données. ✔ Je présente mes démarches pour nettoyer le jeu de données et réduire le nombre d'indicateurs, tout en précisant les hypothèses sous-jacentes. ✔ Je suis satisfait de mon utilisation des graphiques et ai inclus des axes et des titres lisibles pour présenter mes analyses statistiques quand cela était pertinent. ✔ Je me suis efforcé de clarifier le lien entre mes résultats et l'objectif métier pour un interlocuteur de faible niveau technique. ✔ Je suis satisfait par le storytelling de ma présentation.	L'introduction pose la problématique : sc