Année 2025-2026

Mentore : Mr Arnol Namegni

- Projet 2

Analysez les données de systèmes éducatifs

Identification des marchés à fort potentiel pour l'expansion de services EdTech

Candidat : Mr Jean-Francois Chaussoy

Alternant Data Engineering

Contexte Projet & Environnement Technique

Mission :
Accompagner l'expansion internationale d'une start-up EdTech (Academy).

Objectif :
Transformer des données brutes hétérogènes en un score d'attractivité exploitable pour la prise de décision

Problématique business :
Identifier les pays avec le meilleur équilibre entre infrastructure numérique, démographie jeune, richesse et volume scolaire

Sources de Données (World Bank EdStats)

Table de Données :

EdStatsData.csv → Indicateurs temporels par pays/année (millions de lignes)

Tables de Métadonnées :

- EdStatsCountry.csv → Infos pays/régions
- EdStatsSeries.csv → Définitions indicateurs
- EdStatsFootNote.csv → Notes techniques

Environnement :

Google Colab + Drive, Python (Pandas, NumPy, Seaborn, Matplotlib)

Reproductibilité et Environnement Virtuel (Poetry)

```
# ================================================================================
# 1. INITIALISATION DE L'ENVIRONNEMENT & DÉPENDANCES
# ================================================================================
import os
import sys
import subprocess

# Détection de l'environnement (Google Colab ou Local)
try:
    from google.colab import drive
    IN_COLAB = True
except ImportError:
    IN_COLAB = False

# Configuration automatique de Poetry sur Colab
if IN_COLAB:
    # 1. Installation de Poetry
    if os.system("poetry --version") != 0:
        print("Installation de Poetry en cours...")
        os.system("pip install -q poetry")

    # 2. Configuration pour créer le .venv dans le dossier projet
    os.system("poetry config virtualenvs.in-project true")

    # 3. Génération du fichier pyproject.toml avec VOS métadonnées spécifiques
    if not os.path.exists("pyproject.toml"):
        print("Génération du fichier de configuration personnalisé (pyproject.toml)...")

        # Contenu converti au format natif [tool.poetry]
        toml_content = """
[tool.poetry]
name = "academy-edtech-analysis"
version = "0.1.0"
description = "Analyse exploratoire des données de la Banque Mondiale pour Academy EdTech."
authors = ["OpenClassRooms Data Engineering & IA <jf.c.webcraft@gmail.com>"]
readme = "README.md"

[tool.poetry.dependencies]
python = ">=3.9"
pandas = ">=2.0.0"
numpy = ">=1.24.0"
matplotlib = ">=3.7.0"
seaborn = ">=0.12.0"
jupyter = ">=1.0.0"
openpyxl = ">=3.1.0"

[build-system]
requires = ["poetry-core"]
build-backend = "poetry.core.masonry.api"
"""
        with open("pyproject.toml", "w") as f:
            f.write(toml_content)

        # 4. Installation des dépendances
        print("Installation des dépendances via Poetry (cela peut prendre quelques secondes)...")
        os.system("poetry install")
        print("Environnement virtuel configuré avec succès.")
    else:
        print("Fichier pyproject.toml détecté. Environnement déjà configuré.")
```

```
# ================================================================================
# 2. VALIDATION TECHNIQUE
# ================================================================================
# On vérifie que le code peut tourner dans l'environnement virtuel créé
if IN_COLAB:
    print("-" * 50)
    print("Validation de l'environnement virtuel...")

    test_script = "import pandas; print('   [SUCCESS] Pandas importé depuis le venv Poetry')"
    with open("env_check.py", "w") as f:
        f.write(test_script)

    try:
        # On lance via 'poetry run' pour prouver l'isolation
        subprocess.run(["poetry", "run", "python", "env_check.py"], check=True)
        print("CRITÈRE VALIDÉ : Le code fonctionne dans l'environnement virtuel.")
    except subprocess.CalledProcessError:
        print("ERREUR : Le code a échoué dans l'environnement virtuel.")
    print("-" * 50)

# ================================================================================
# 3. IMPORTS DES LIBRAIRIES (DANS LE NOTEBOOK)
# ================================================================================
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# ================================================================================
# 4. MONTAGE DU STORAGE (GOOGLE DRIVE)
# ================================================================================
if IN_COLAB:
    mount_path = '/content/drive'
    if not os.path.exists(mount_path):
        print(f"Montage du volume distant vers {mount_path}...")
        drive.mount(mount_path)
    else:
        pass # Le drive est déjà monté
```

Le bloc de code

#Analysez des données de systèmes éducatifs (extrait de Exercice 1 #Etape 1 Configuration et Initialisation de l'Environnement

Configuration et Importation via Google Colaab

```python
# ==============================================================================
# 5. CONFIGURATION GLOBALE (CONSTANTES)
# ==============================================================================

# Chemin racine (Point de montage)
BASE_PATH = "/content/drive/MyDrive/data/"

CONFIG = {
    # Chemins relatifs vers les sources de données
    "PATHS": {
        "DATA": os.path.join(BASE_PATH, "EdStatsData.csv"),
        "METADATA": os.path.join(BASE_PATH, "EdStatsCountry.csv"),
        "SERIES": os.path.join(BASE_PATH, "EdStatsSeries.csv"),
        "FOOTNOTE": os.path.join(BASE_PATH, "EdStatsFootNote.csv")
    },

    # Indicateurs retenus pour le scoring
    "INDICATORS": [
        'IT.NET.USER.P2',
        'SP.POP.0014.TO.ZS',
        'NY.GDP.PCAP.PP.CD',
        'SE.SEC.ENRL'
    ],

    # Mapping pour l'affichage (Codes -> Labels FR)
    "LABELS": {
        'IT.NET.USER.P2': 'Internet (%)',
        'SP.POP.0014.TO.ZS': 'Jeunesse (<14ans %)',
        'NY.GDP.PCAP.PP.CD': 'Richesse (PIB/hab $)',
        'SE.SEC.ENRL': 'Volume Élèves (Sec.)'
    },

    # Pondération métier pour le calcul du score
    "WEIGHTS": {
        'IT.NET.USER.P2': 0.3,
        'SP.POP.0014.TO.ZS': 0.3,
        'NY.GDP.PCAP.PP.CD': 0.2,
        'SE.SEC.ENRL': 0.2
    },

    # Fenêtre temporelle d'analyse
    "YEAR_RANGE": [2010, 2020]
}

print(f"Pipeline initialisé. Chargement des données depuis : {BASE_PATH}")
```

```
Fichier pyproject.toml détecté. Environnement déjà configuré.
--------------------------------------------------
Validation de l'environnement virtuel...
CRITÈRE VALIDÉ : Le code fonctionne dans l'environnement virtuel.
--------------------------------------------------
Pipeline initialisé. Chargement des données depuis : /content/drive/MyDrive/data/
```

Le bloc de code

#Analysez des données de systèmes éducatifs (extrait de Exercice 1 #Etape 1 Configuration et Initialisation de l'Environnement

Test de validité d'environnement virtuel

```python
# ==============================================================================
# 5. TEST UNITAIRE : VALIDATION DE L'ENVIRONNEMENT VIRTUEL (SANDBOX)
# ==============================================================================
import subprocess

# Création du script de test
test_script = """
import sys
import pandas as pd
print(f"   [OK] Interpréteur python : {sys.executable}")
print(f"   [OK] Pandas version : {pd.__version__}")
print("   [SUCCESS] L'environnement virtuel est fonctionnel.")
"""

with open("env_check.py", "w") as f:
    f.write(test_script)

print("Lancement du test de l'environnement virtuel...")
print("-" * 50)

# Exécution via subprocess pour capturer l'affichage
try:
    result = subprocess.run(
        ["poetry", "run", "python", "env_check.py"],
        capture_output=True,
        text=True,
        check=True
    )
    # Affiche la sortie standard du script (les print)
    print(result.stdout)
    print("VALIDATION RÉUSSIE : Code de sortie 0")

except subprocess.CalledProcessError as e:
    # En cas d'erreur
    print("ÉCHEC DU TEST")
    print(e.stderr)
```

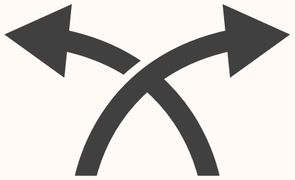
```
Lancement du test de l'environnement virtuel...
--------------------------------------------------
   [OK] Interpréteur python : /content/.venv/bin/python
   [OK] Pandas version : 2.3.3
   [SUCCESS] L'environnement virtuel est fonctionnel.

VALIDATION RÉUSSIE : Code de sortie 0
```

Le bloc de code

#Analysez des données de systèmes éducatifs (extrait de Exercice 1 #Etape 1 Configuration et Initialisation de l'Environnement

Problématiques dans les Données Brutes



Contenu principal :

Granularité mixte : Mélange Pays souverains + Agrégats régionaux (ex: "World", "Euro Area")



Risque :

Double comptage si on ne filtre pas



Clé de nettoyage :

Colonne Region dans EdStatsCountry.csv

- Region renseignée → Pays souverain
- Region = NaN → Agrégat à exclure

Beaucoup de valeurs manquantes (trous irréguliers)



Précision :

Table de Faits (EdStatsData.csv) :

Contenu : Toutes les mesures quantitatives (KPIs) historiques.

Problème identifié : Granularité mixte.

Les lignes mélangent des Pays souverains (ex: France) et des Agrégats régionaux
(ex: Arab World, Euro Area).

Risque : Double comptage statistique si non filtré.

Table de Dimension Pays (EdStatsCountry.csv) :

Contenu : Métadonnées géographiques
et économiques.

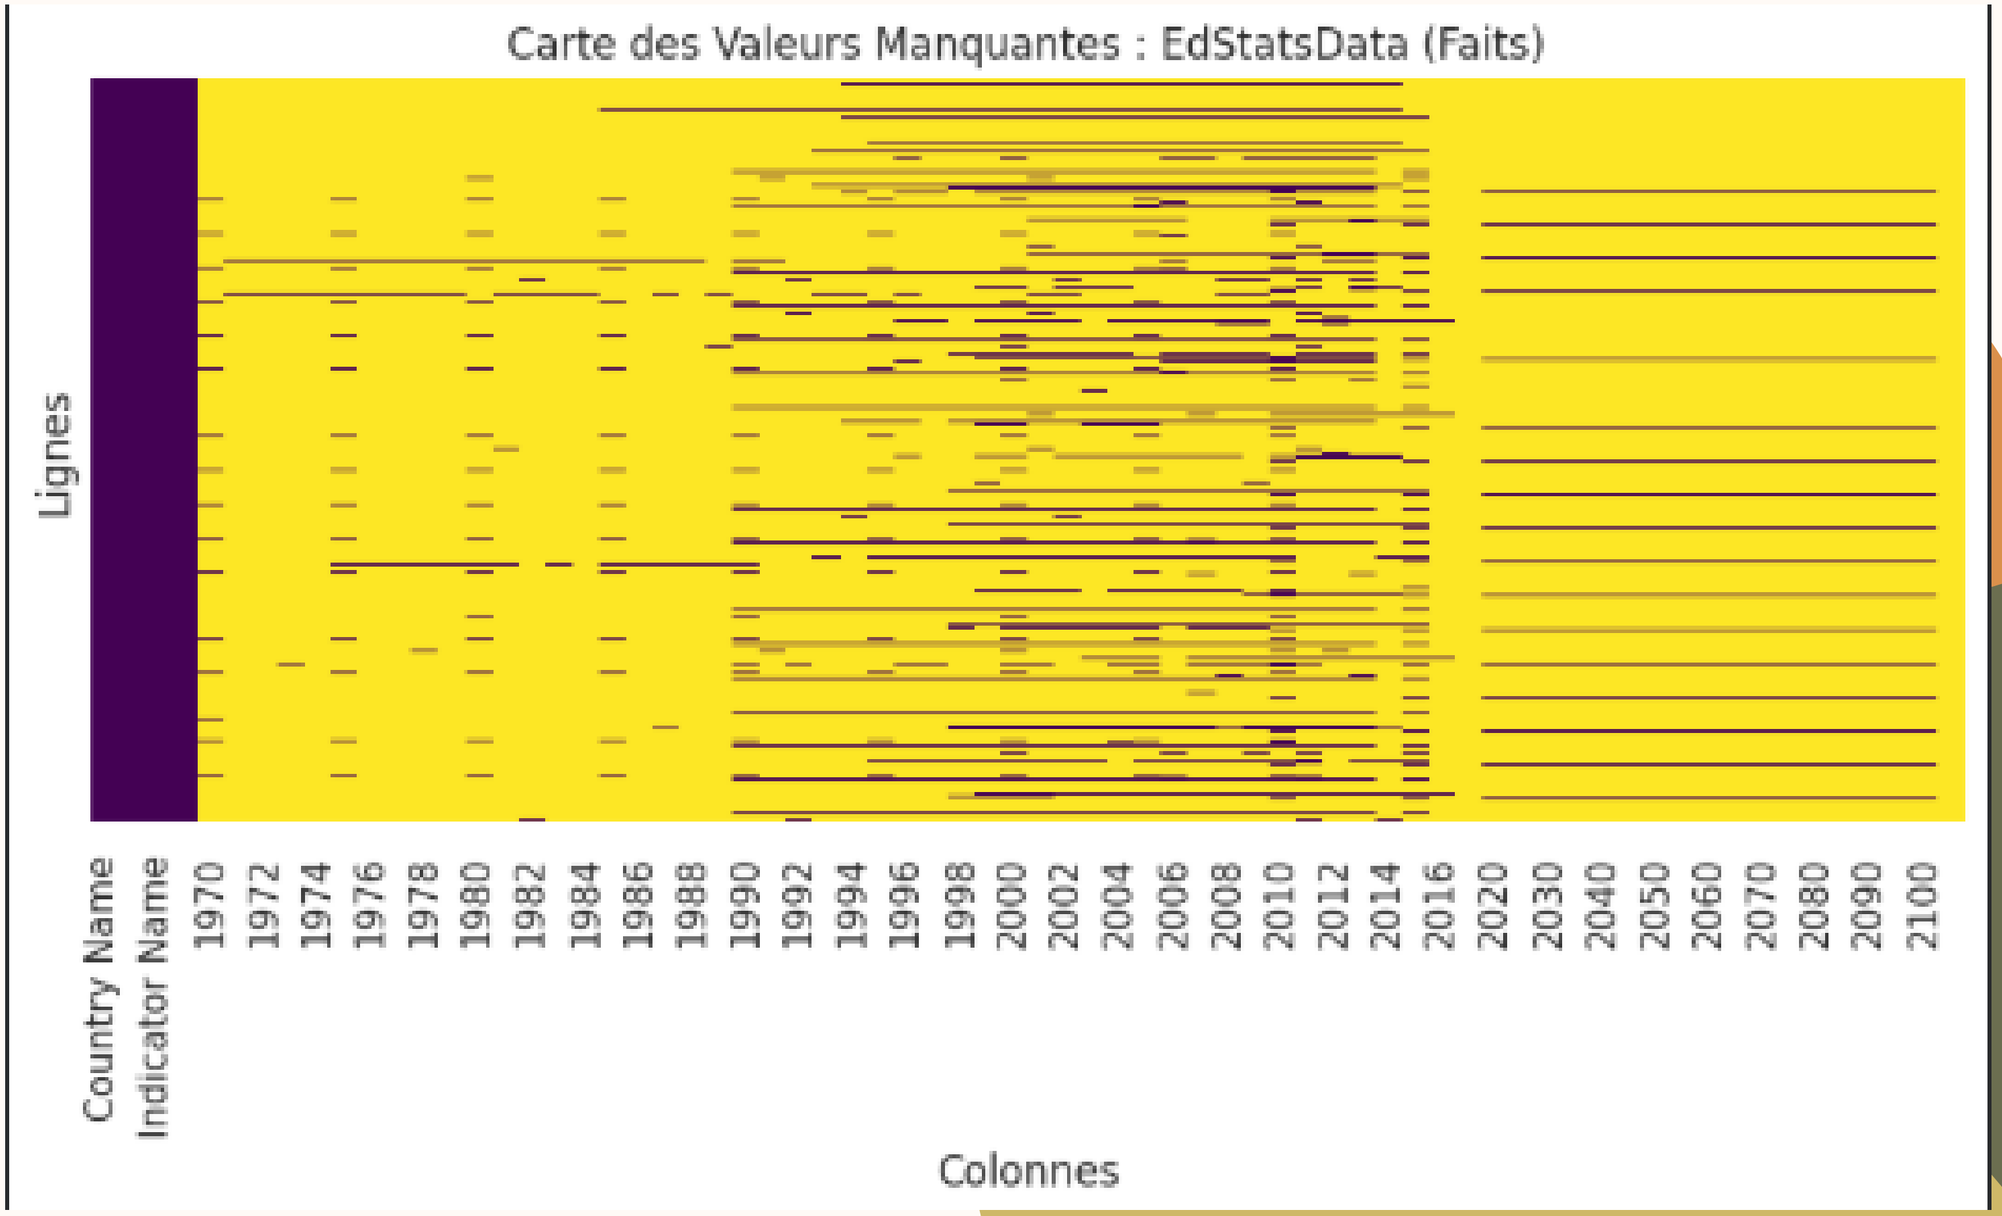
La Clé du Nettoyage : La colonne Region.

- Si Region est renseignée ➔ C'est un Pays.
- Si Region est vide (NaN) ➔ C'est un Agrégat.

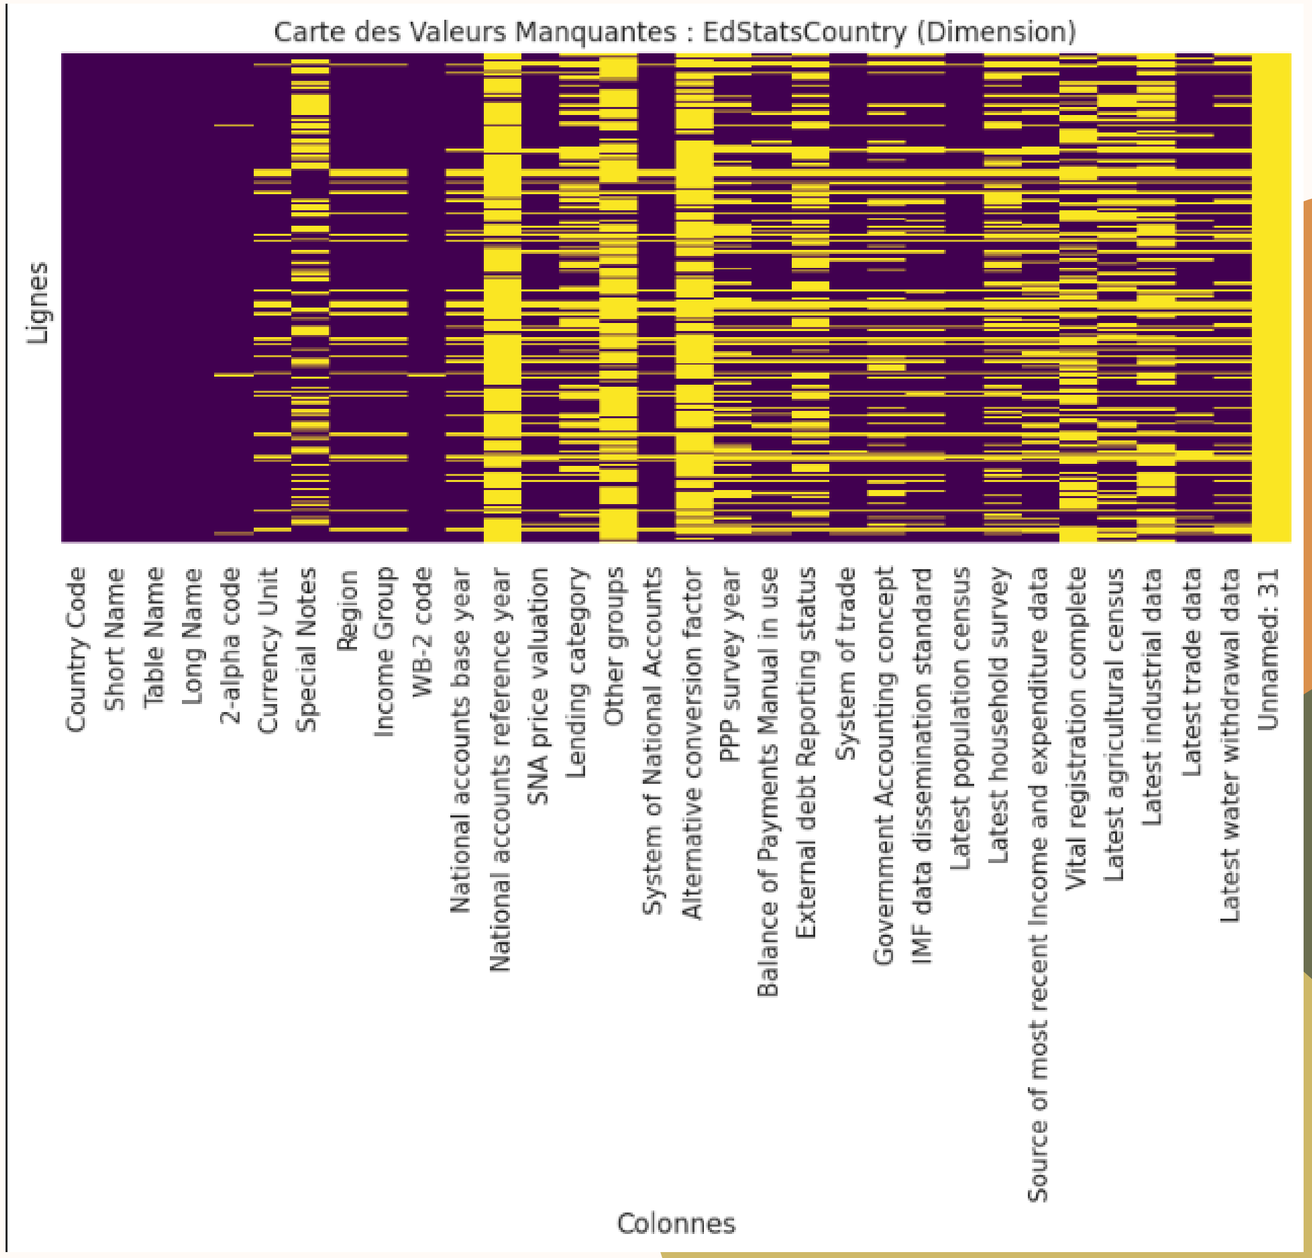
Tables Annexes :

- EdStatsSeries.csv : Dictionnaire des indicateurs (Codes = Définitions).
- EdStatsFootNote.csv : Méta-informations techniques.

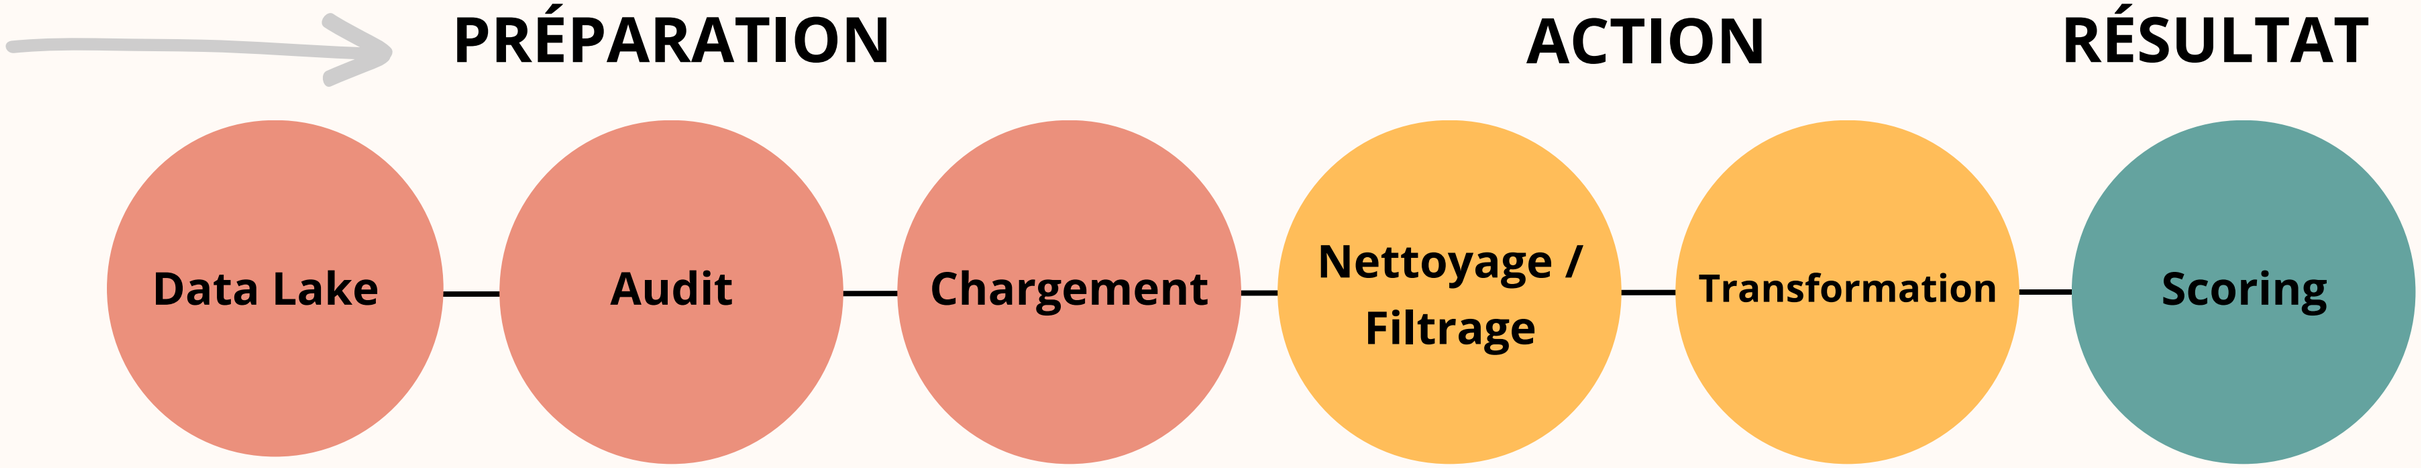
Heatmap (carte thermique des valeurs manquantes - Faits)



Heatmap (carte thermique des valeurs manquantes - Dimensions)



Pipeline ETL – Du Data Lake au Scoring



Filtrage :

Pays souverains + 4 indicateurs ciblés → 856 lignes analysables

Résultat après nettoyage :

Prêt pour transformation

Gestion des Missing Values & Agrégation Temporelle

Problème :

Trous irréguliers dans les données annuelles

Solution :

Moyenne sur 2010-2020
→ Lisse variations + comble manques

Pivot :

Format Long → Wide (1 ligne = 1 pays)

Nettoyage final :

Drop pays incomplets
→ 163 pays qualifiés

Exemple partie nettoyage et filtrage réalisé :

```python
print(f"--- Étape 4 : Nettoyage & Filtrage ---")

# 1. Identification des Pays Valides (vs Agrégats)
# Règle : Si la 'Region' est NaN, c'est un agrégat (ex: World, Arab World) -> On supprime.
df_valid_countries = df_country.dropna(subset=['Region']).copy()
valid_country_codes = df_valid_countries['Country Code'].unique()

print(f"1. Filtrage des Entités Géographiques :")
print(f"   - Total entités dans le fichier : {len(df_country)}")
print(f"   - Pays souverains conservés : {len(valid_country_codes)}")
print(f"   - Agrégats supprimés : {len(df_country) - len(valid_country_codes)}")

# 2. Application du filtre Pays sur la Data (Table de Faits)
# On ne garde que les lignes dont le Country Code est dans notre liste validée
rows_before = len(df_data)
df_clean = df_data[df_data['Country Code'].isin(valid_country_codes)].copy()
rows_after_country = len(df_clean)

print(f"2. Filtrage de la Table de Faits (Pays) :")
print(f"   - Lignes avant : {rows_before}")
print(f"   - Lignes après suppression des agrégats : {rows_after_country}")
```

```
--- Étape 4 : Nettoyage & Filtrage ---
1. Filtrage des Entités Géographiques :
   - Total entités dans le fichier : 241
   - Pays souverains conservés : 214
   - Agrégats supprimés : 27
2. Filtrage de la Table de Faits (Pays) :
   - Lignes avant : 886930
   - Lignes après suppression des agrégats : 784310
```

Le bloc de code

#Analysez des données de systèmes éducatifs
(extrait de Exercice 1
#Étape 4 : Nettoyage & Filtrage (Règles Métier))

Exemple partie nettoyage et filtrage réalisé :

```
print(f"--- Étape 4 : Nettoyage & Filtrage ---")

# 1. Identification des Pays Valides (vs Agrégats)
# Règle : Si la 'Region' est NaN, c'est un agrégat (ex: World, Arab World) -> On supprime.
df_valid_countries = df_country.dropna(subset=['Region']).copy()
valid_country_codes = df_valid_countries['Country Code'].unique()

print(f"1. Filtrage des Entités Géographiques :")
print(f"   - Total entités dans le fichier : {len(df_country)}")
print(f"   - Pays souverains conservés : {len(valid_country_codes)}")
print(f"   - Agrégats supprimés : {len(df_country) - len(valid_country_codes)}")

# 2. Application du filtre Pays sur la Data (Table de Faits)
# On ne garde que les lignes dont le Country Code est dans notre liste validée
rows_before = len(df_data)
df_clean = df_data[df_data['Country Code'].isin(valid_country_codes)].copy()
rows_after_country = len(df_clean)

print(f"2. Filtrage de la Table de Faits (Pays) :")
print(f"   - Lignes avant : {rows_before}")
print(f"   - Lignes après suppression des agrégats : {rows_after_country}")

# 3. Application du filtre Indicateurs
# On ne garde que les indicateurs définis dans la CONFIG
df_clean = df_clean[df_clean['Indicator Code'].isin(CONFIG["INDICATORS"])].copy()
rows_final = len(df_clean)

print(f"3. Filtrage des Indicateurs (Sélection : {len(CONFIG['INDICATORS'])} indicateurs) :")
print(f"   - Lignes restantes pour l'analyse : {rows_final}")

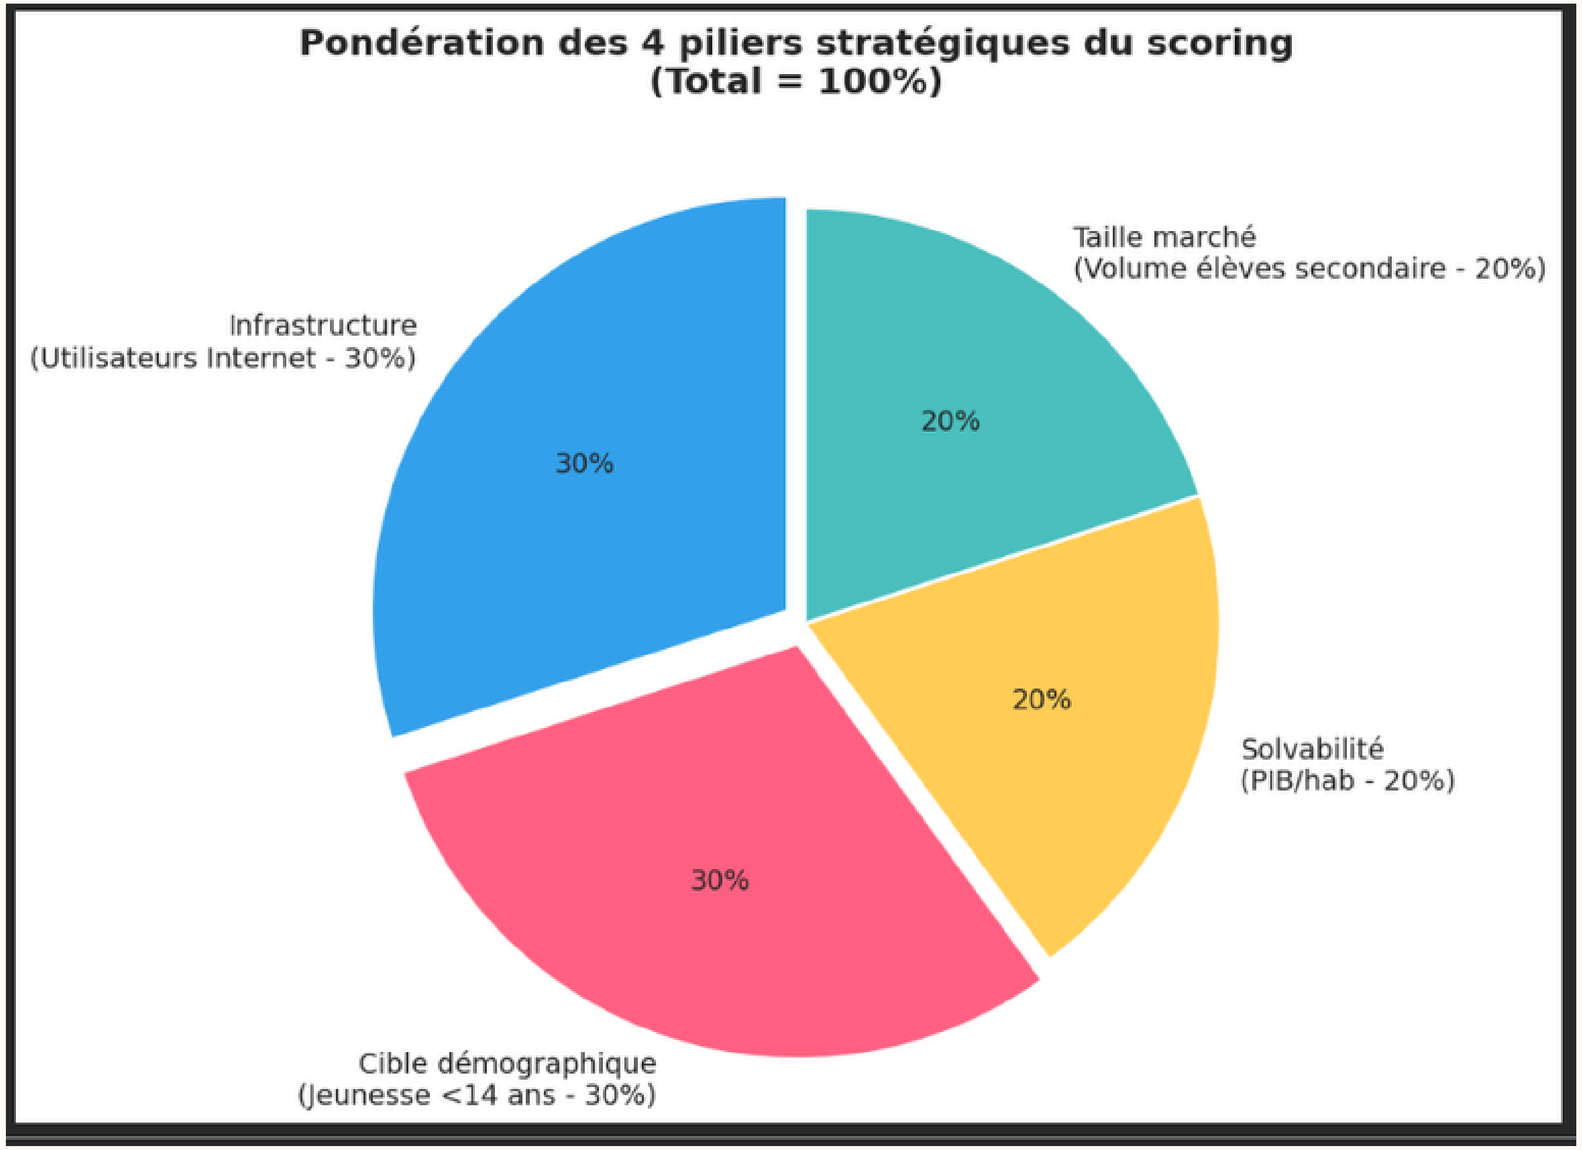
# Petit check de sécurité
if df_clean.empty:
    print("ALERTE : Le DataFrame est vide après filtrage ! Vérifiez les codes indicateurs dans CONFIG.")
else:
    print(f"Nettoyage terminé. Prêt pour la transformation (Pivot).")
```

```
--- Étape 4 : Nettoyage & Filtrage ---
1. Filtrage des Entités Géographiques :
   - Total entités dans le fichier : 241
   - Pays souverains conservés : 214
   - Agrégats supprimés : 27
2. Filtrage de la Table de Faits (Pays) :
   - Lignes avant : 886930
   - Lignes après suppression des agrégats : 784310
3. Filtrage des Indicateurs (Sélection : 4 indicateurs)
   - Lignes restantes pour l'analyse : 856
Nettoyage terminé. Prêt pour la transformation (Pivot).
```

Le bloc de code

#Analysez des données de systèmes éducatifs
(extrait de Exercice 1
#Étape 4 : Nettoyage & Filtrage (Règles Métier))

Sélection des Indicateurs & Pondération Métier



Mécanique du Scoring :
De la donnée brute au classement décisionnel

Normalisation Min-Max :

Problème : Comment comparer et additionner des indicateurs aux unités différentes ?

- % d'utilisateurs Internet → entre 0 et 100
- PIB par habitant → entre 700 $ et 127 000 $
- Volume d'élèves → entre 7 000 et 119 millions

Solution : Normalisation Min-Max

Formule appliquée à chaque indicateur :

$$Val_{norm} = \frac{Valeur - Min}{Max - Min}$$

Résultat :

Toutes les valeurs sont ramenées entre 0 et 1

Sécurité :

Si Min = Max → Valeur normalisée = 0 (cas rare)

Calcul du Score Pondéré

$$Total_Score = (Internet_{norm} \times 0.3) + (Jeunesse_{norm} \times 0.3) + (PIB_{norm} \times 0.2) + (Volume_{norm} \times 0.2)$$

- La formule présentée est une moyenne pondérée (Weighted Average). Elle traduit la stratégie commerciale en équation mathématique.

Extrait Resultats_scoring_edtech_FR

- 20 premiers du data frame créés

	A	B	C	D	E	F	G	H	I	J	K
2	Country Name	Country Code	Internet (%)	Richesse (PIB/hab $)	Volume Élèves (Sec.)	Jeunesse (<14ans %)	IT.NET.USER.P2_norm	SP.POP.0014.TO.ZS_norm	NY.GDP.PCAP.PP.CD_norm	SE.SEC.ENRL_norm	Total_Score
3	Luxembourg	LUX	93.69633035571428	96308.96797391486	44615.6	16.925008775118958	0.9705784703598103	0.1433980928543641	0.7567328398699406	0.0003105029772908717 5	0.4856016375334586 4
4	Qatar	QAT	81.60942065714286	127041.21337085943	80259.66666666667	13.516793773715298	0.8441662802489487	0.0555518647045681 05	1.0	0.0006079918489495435	0.4700370417559541
5	Norway	NOR	95.28455205285715	62852.12792788214 6	437254.6666666667	18.2959815722979	0.9871090505753 81	0.1787348798645655 4	0.4918986125038788 4	0.0035875015840603436	0.4888744019495703 6
6	Iceland	ISL	96.50947180714286	43482.04303352384	36301.25	20.505129808779525	1.0	0.2356751730847205 2	0.3385708786248181	0.0002411107143212795 4	0.4284648493793244
7	Brunei Darussalam	BRN	64.10615214857144	80572.31162810748	49838.66666666666 4	24.57131077731643	0.6611065436055531	0.3404803749024875	0.6321662275140518	0.0003540951300918778	0.4269801400812409
8	Kuwait	KWT	72.52424620857143	75562.79478918388	275622.3333333333	21.890758726283 44	0.7491480474485804	0.2713895497140016 4	0.5925124072582169	0.0022401737801566457	0.4251117953564493 3
9	United States	USA	73.03577145571428	53015.344611959	24170952.4	19.590525877031357	0.7544976869361346	0.2121013945461129 3	0.4140336107387529	0.2016709349675907 8	0.4131206935859 43
10	Denmark	DNK	93.52971576571427	46530.735310042646	535583.8333333334	17.297797501945 57	0.9688359145071469	0.1530066661207207	0.3627034046618803 4	0.0044081650623826 45	0.4099750681332129
11	Netherlands	NLD	91.82259209285715	48058.785785829416	1553925.3333333333	17.053326304439388	0.9509817051428617	0.1467054578391606	0.3747989900969669 6	0.0129073286964429 13	0.4068474396530886 7
12	Israel	ISR	72.79611771714285	33487.479134087225	744294.8333333334	27.647607377729 27	0.7519914436254462	0.4197714562764649	0.2594569334785879 6	0.0061500845866365 29	0.4046502735836222
13	Macao SAR, China	MAC	67.36211629142858	118453.88912515536	34539.166666666664	12.460416335514784	0.6951593799783646	0.0283238953979837 07	0.9320253383576025	0.0002264042189198347 4	0.4034953311282 09
14	Ireland	IRL	77.41282364428571	53717.05744166142	342225.2	21.349079621584572	0.8002757381141533	0.2574278523529346 4	0.4195681572778582 5	0.0027943776789181 97	0.4018785841314817
15	Sweden	SWE	92.19598035285716	45681.63811968152	769249.1666666666	16.891598057880856	0.9548650225509 5	0.1425603666515019 7	0.3559822080976333 7	0.0063583555472123 77	0.4016947094897047
16	Bahrain	BHR	84.56877450285715	43140.37970649957	86054.83333333333	20.480278625611586	0.8751169872763696	0.2350346375828627 8	0.3358663750582142	0.0006636582969159727	0.4003500341287958
17	India	IND	17.3996034	5309.820325289201	119624084.0	29.567029605776617	0.1726212924509822 3	0.4692442801624696 6	0.0368068930684643 2	1.0	0.3999210503977284 6
18	United Kingdom	GBR	89.4414568	39096.00521057089	5686360.3	17.56408368482707	0.9260784369978 94	0.1596701575184635 3	0.3062270389602686	0.0474136609543416 74	0.3965127203962935
19	Saudi Arabia	SAU	58.72562812142856	50876.045262041865	3409842.0	27.412473557026 99	0.6048358705605393	0.4137109174751749 6	0.3970995640786229 6	0.0283909648973840713	0.3990633422212 07
20	Switzerland	CHE	86.41680741142856	59448.21384759247	610657.1666666666	14.863362326738471	0.894444829809651	0.0902594662729834 5	0.4640542580988109	0.0050347334037046 39	0.3894090871252934 3

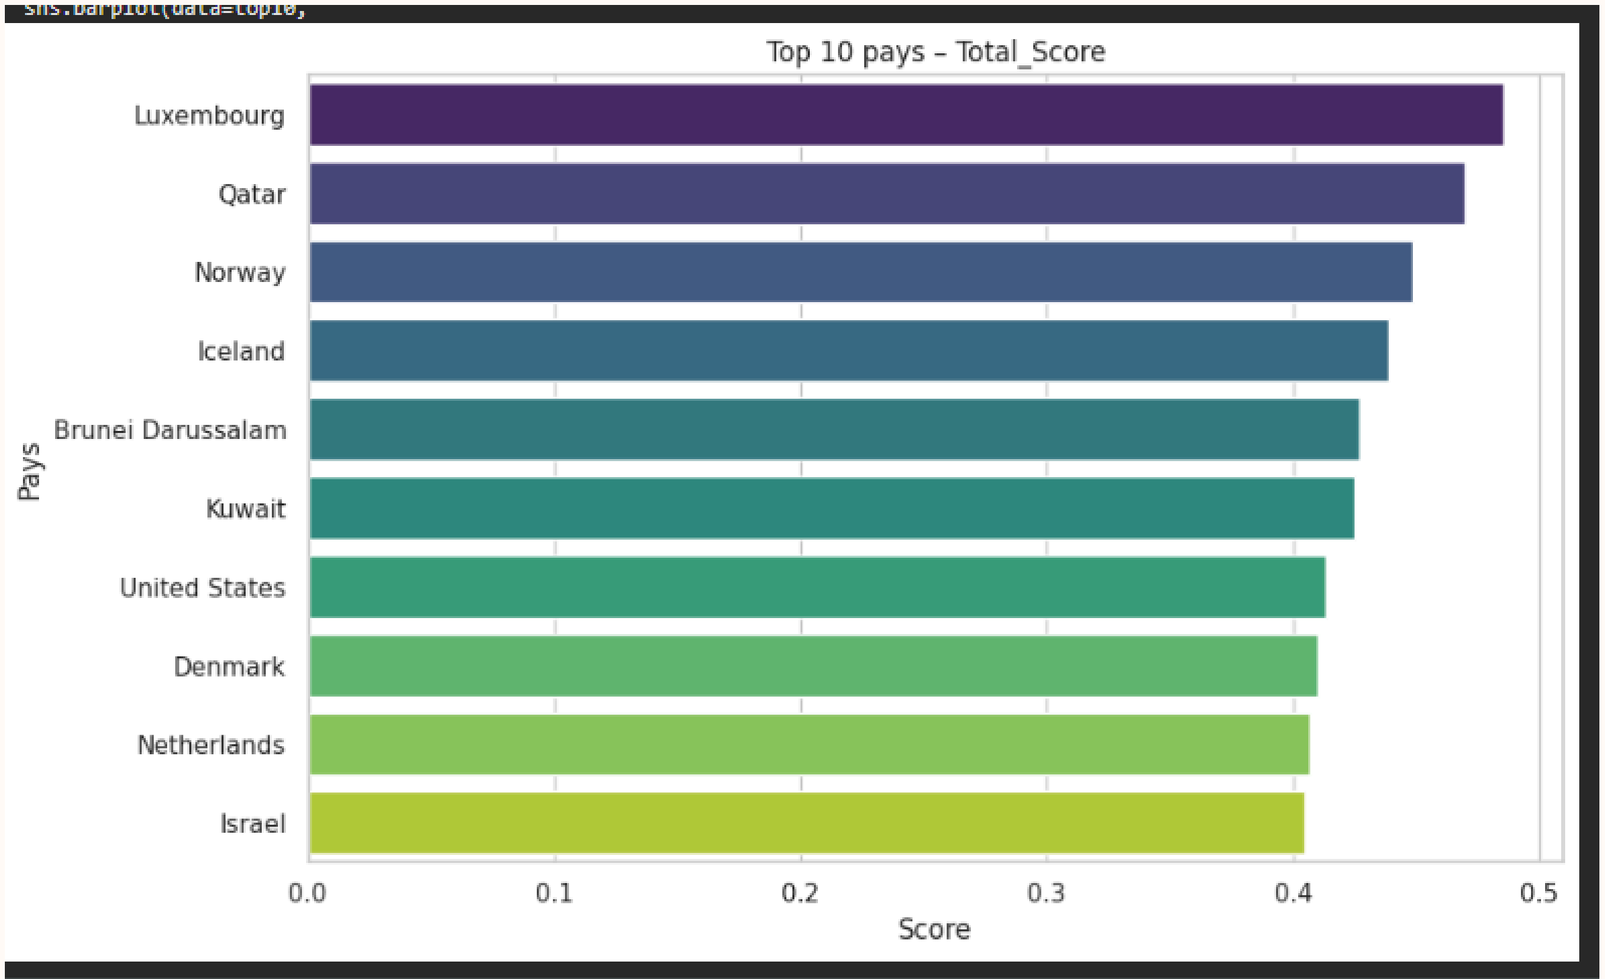
Exemple concret : Luxembourg (1er du classement) :

Indicateur	Valeur brute	Min global	Max global	Valeur normalisée	Contribution (× poids)
Internet (%)	93,70%	0,89%	96,51%	(93,70 – 0,89) / (96,51 – 0,89) = **0,969**	0,969 × 0,3 = **0,291**
Jeunesse (<14 ans %)	16,93%	11,36%	50,16%	(16,93 – 11,36) / (50,16 – 11,36) = **0,144**	0,144 × 0,3 = **0,043**
PIB/hab (PPP $)	96 309 $	710 $	127 041 $	(96 309 – 710) / (127 041 – 710) = **0,757**	0,757 × 0,2 = **0,151**
Volume élèves secondaire	44 616	7 412	119 824 084	(44 616 – 7 412) / (119 824 084 – 7 412) ≈ **0,0003**	0,0003 × 0,2 ≈ **0,000**
Total Score					**≈ 0,4856 → 0,49**

Top 10 Pays Cibles :

```
--- TOP 10 PAYS CIBLES ---
Indicator Code                 Total_Score  IT.NET.USER.P2  SP.POP.0014.TO.ZS  NY.GDP.PCAP.PP.CD   SE.SEC.ENRL
Country Name      Country Code
Luxembourg        LUX             0.485602       93.696330          16.925009       96308.967974  4.461560e+04
Qatar             QAT             0.470037       81.609421          13.516794      127041.213371  8.025967e+04
Norway            NOR             0.448874       95.284552          18.295988       62852.127928  4.372547e+05
Iceland           ISL             0.438465       96.509472          20.505130       43482.043034  3.630125e+04
Brunei Darussalam BRN             0.426980       64.106152          24.571311       80572.311628  4.983867e+04
Kuwait            KWT             0.425112       72.524246          21.890759       75562.794789  2.758223e+05
United States     USA             0.413121       73.035771          19.590526       53015.344612  2.417095e+07
Denmark           DNK             0.409975       93.529716          17.297798       46530.735310  5.355838e+05
Netherlands       NLD             0.406847       91.822593          17.053326       48058.785786  1.553925e+06
Israel            ISR             0.404650       72.796118          27.647607       33487.479134  7.442948e+05
```

```
sns.barplot(data=top10,
```



Interprétation Stratégique des Résultats :

Top 3 :
Marchés premium mais petits/saturés

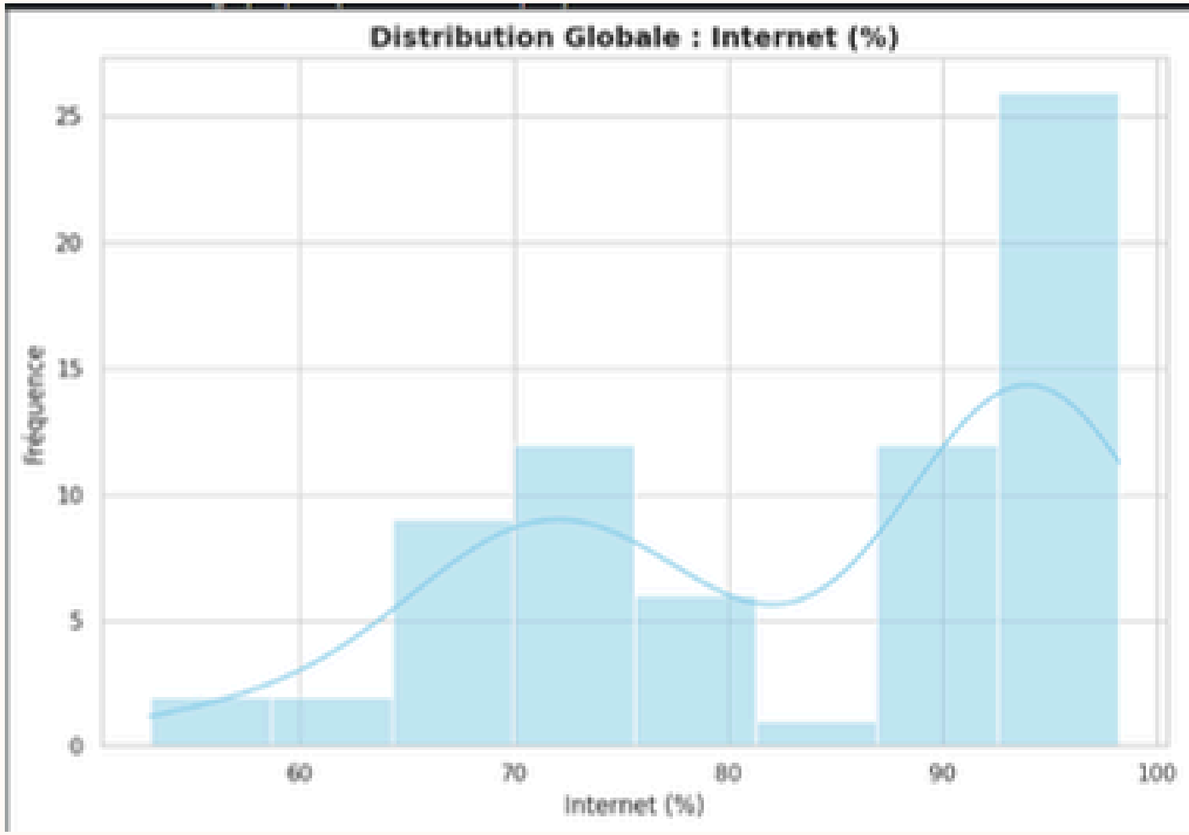
USA (7e) :
Meilleur compromis volume/score → Cible prioritaire pour scale-up

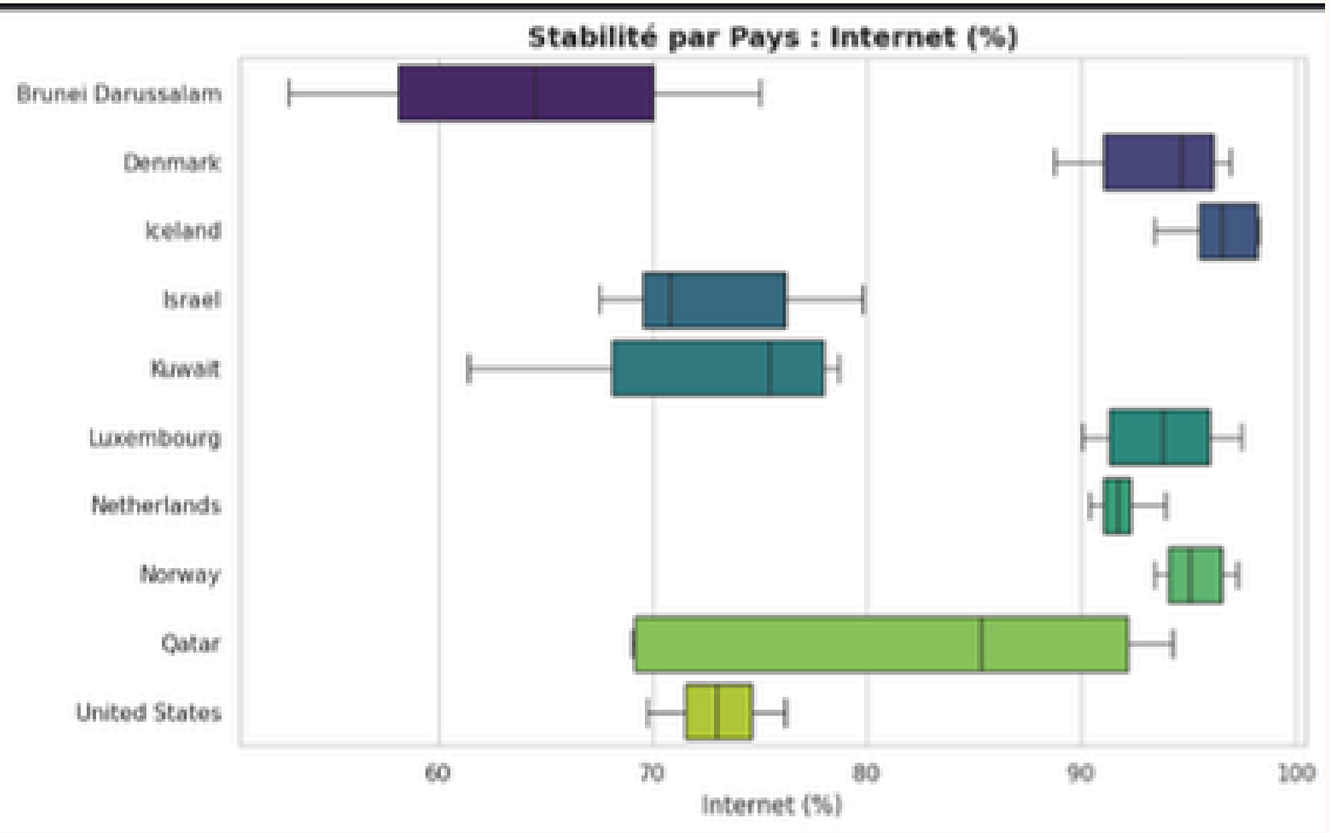
Recommandation :
2 axes selon risque

- Pilote sécurisé : Luxembourg/Norvège
- Expansion massive : USA

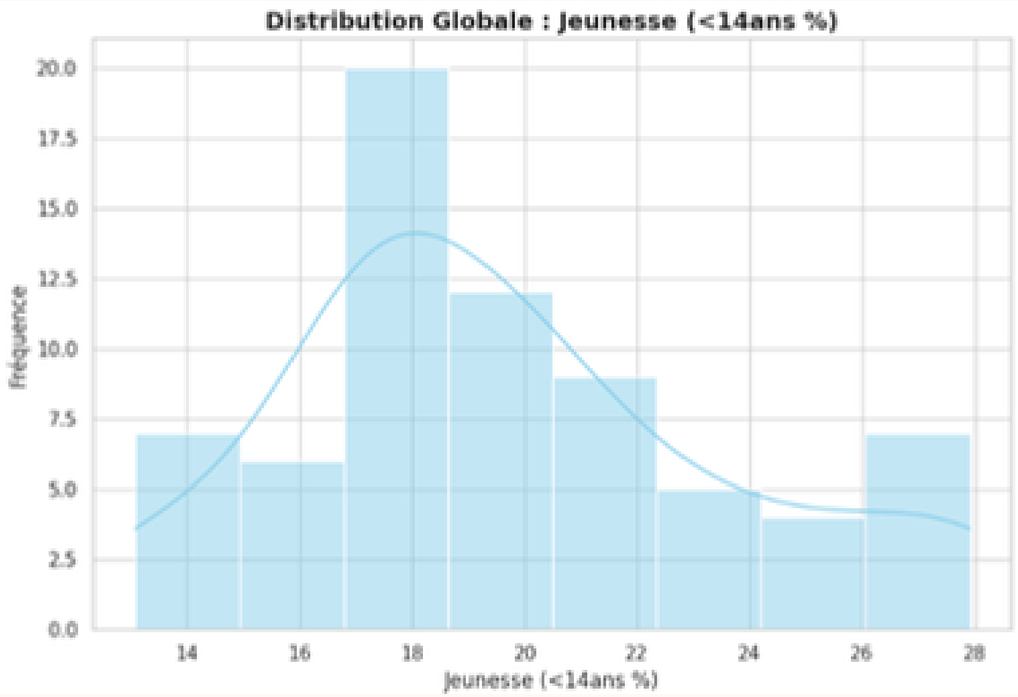
Analyse Exploratoire Approfondie :

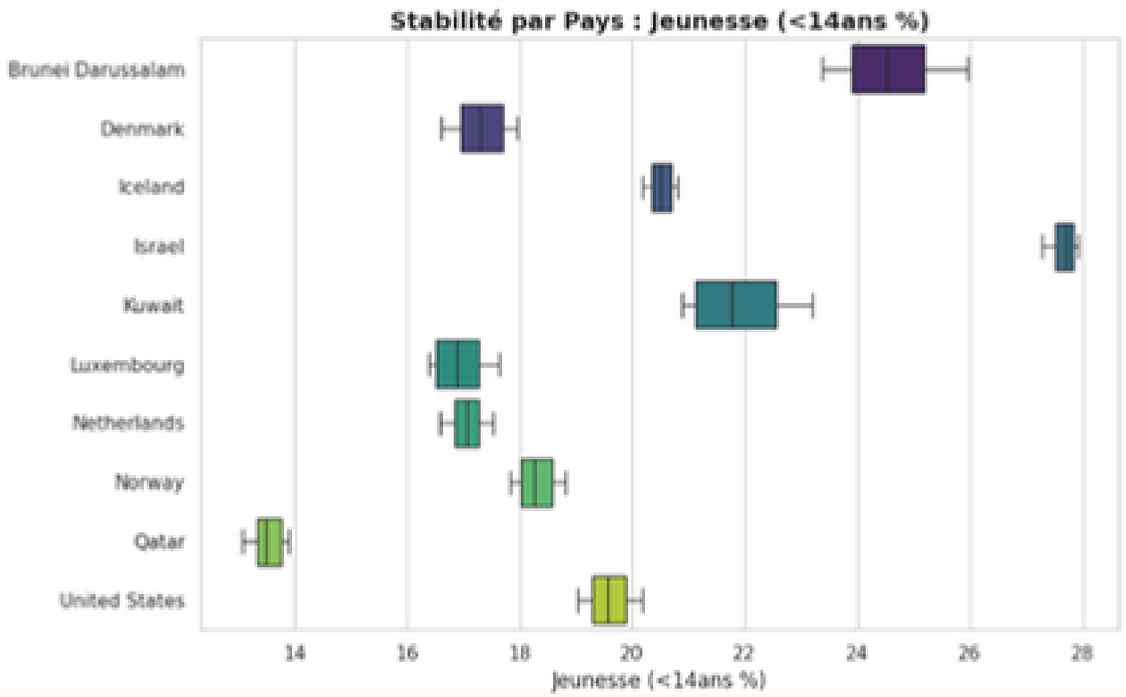
Boxplots : Stabilité des indicateurs dans le Top 10

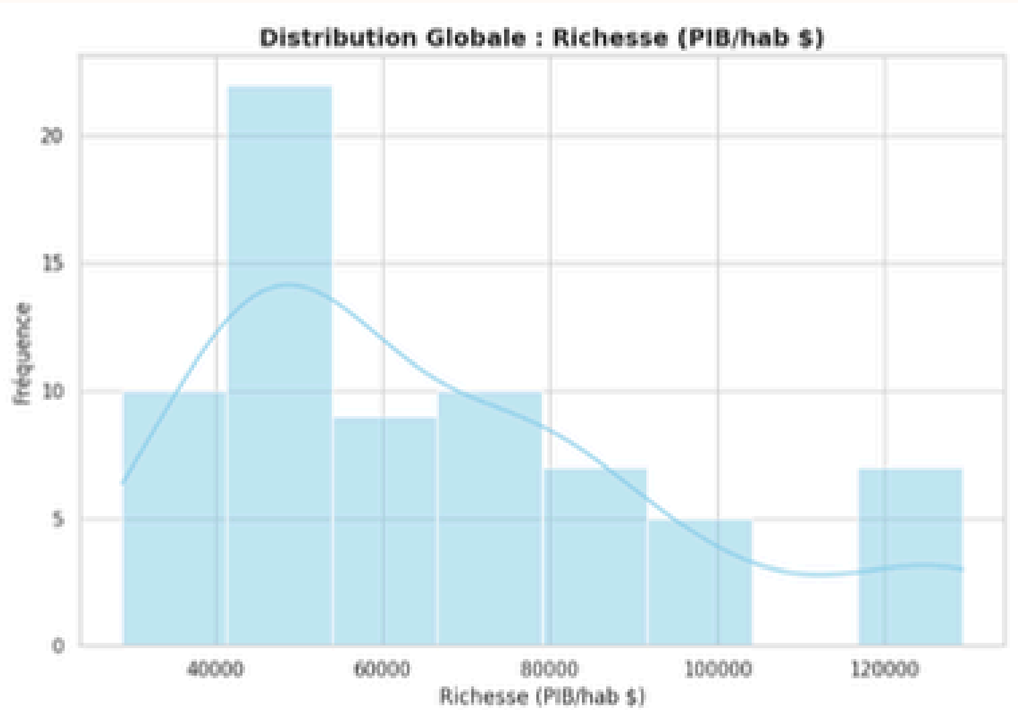


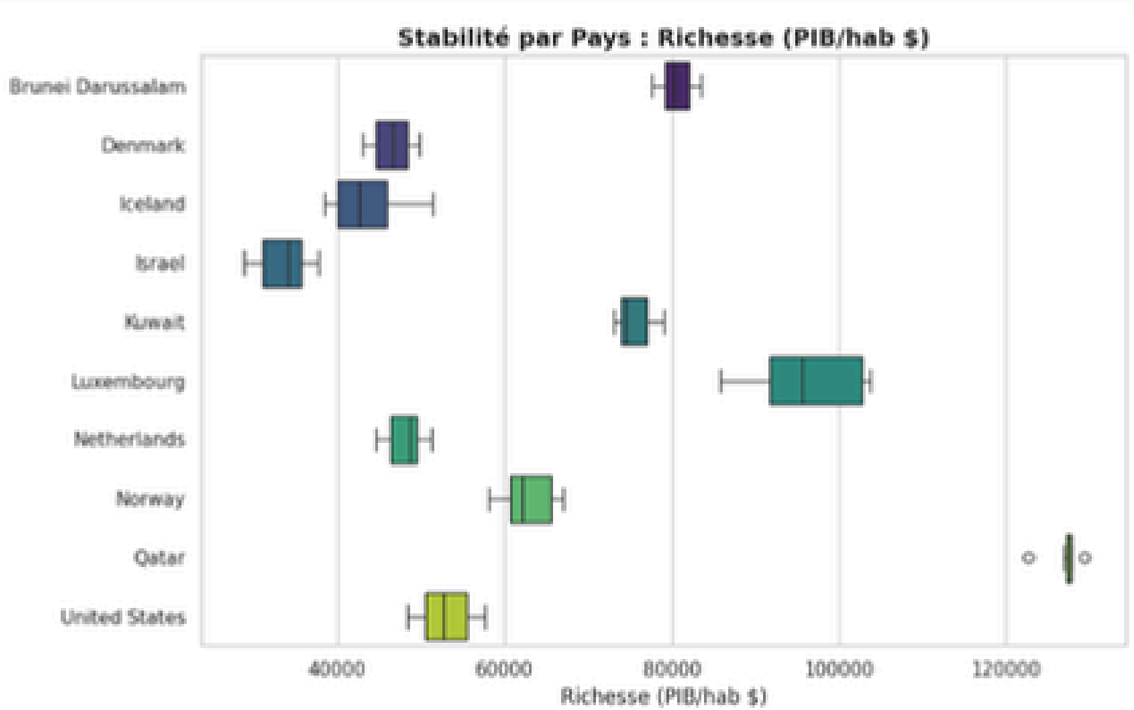


Boxplots : Stabilité des indicateurs dans le Top 10

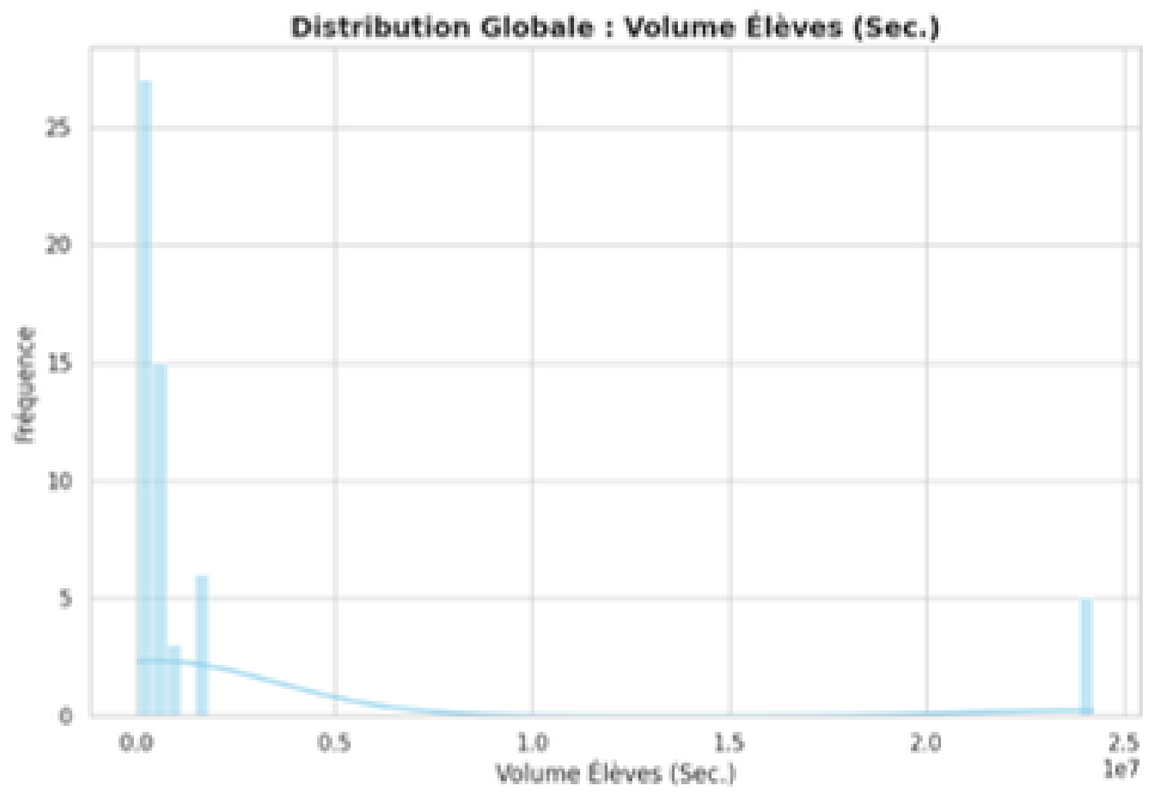


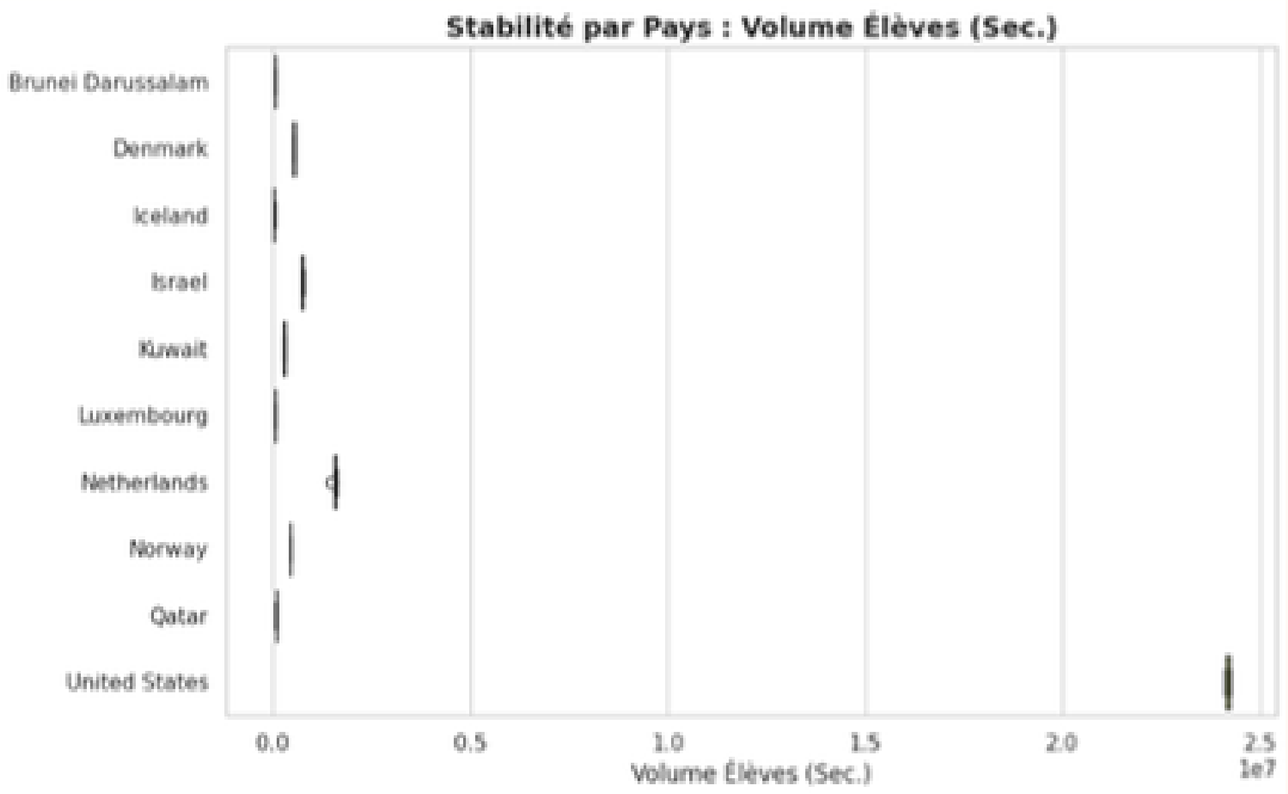




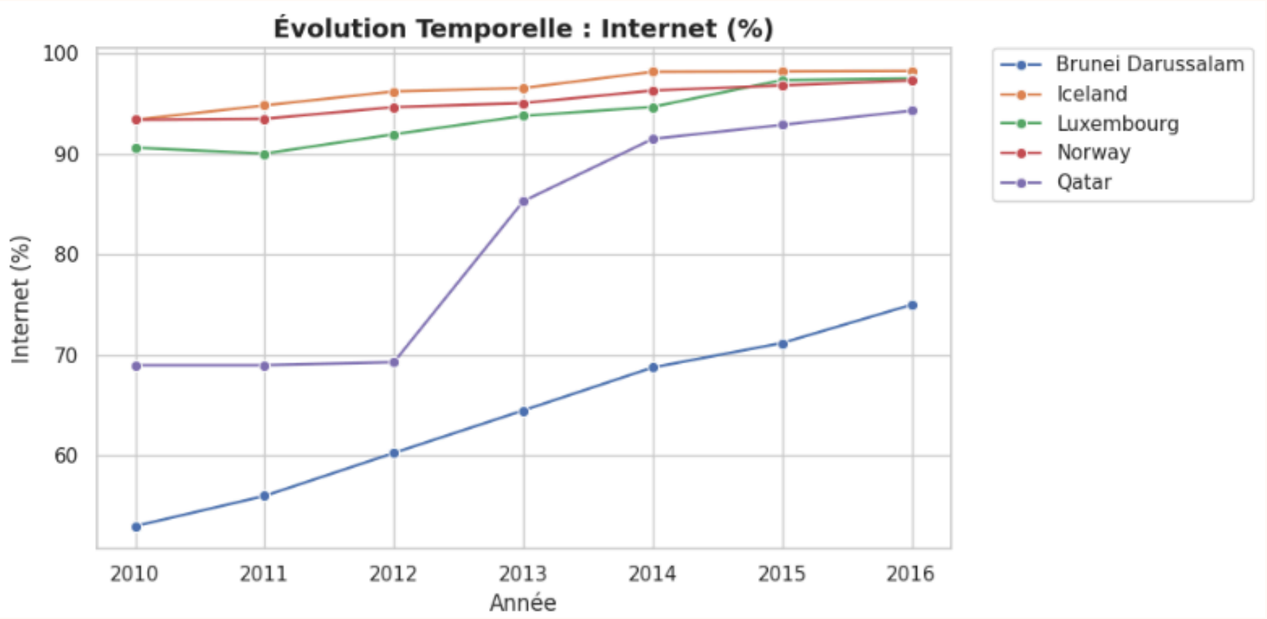


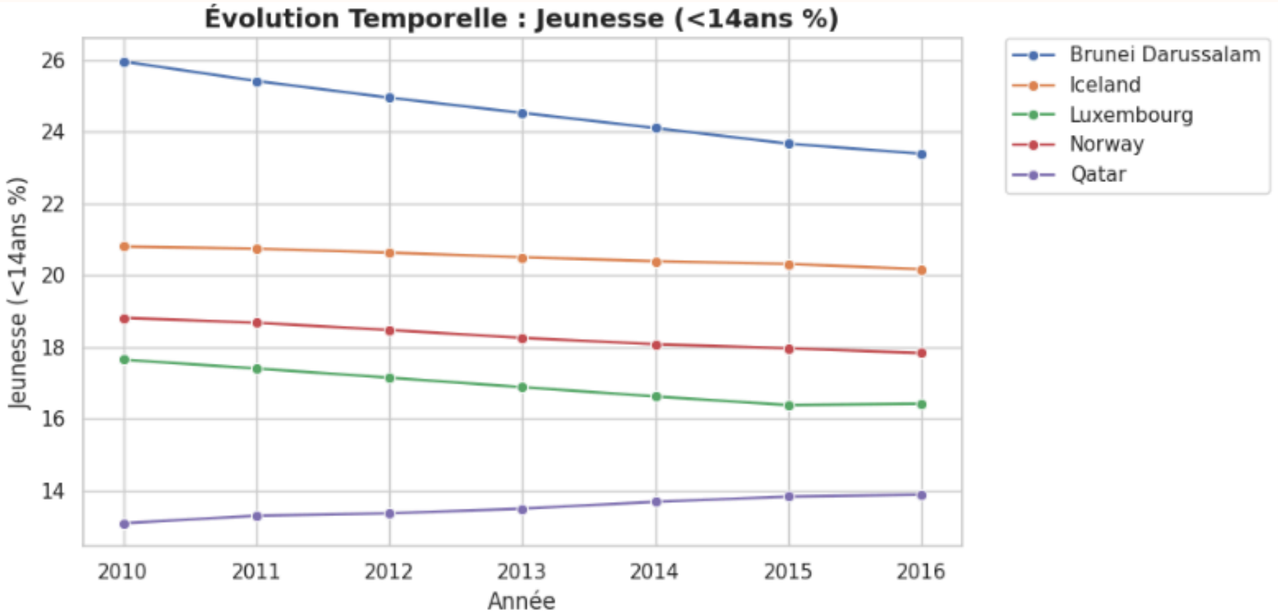
Boxplots : Stabilité des indicateurs dans le Top 10

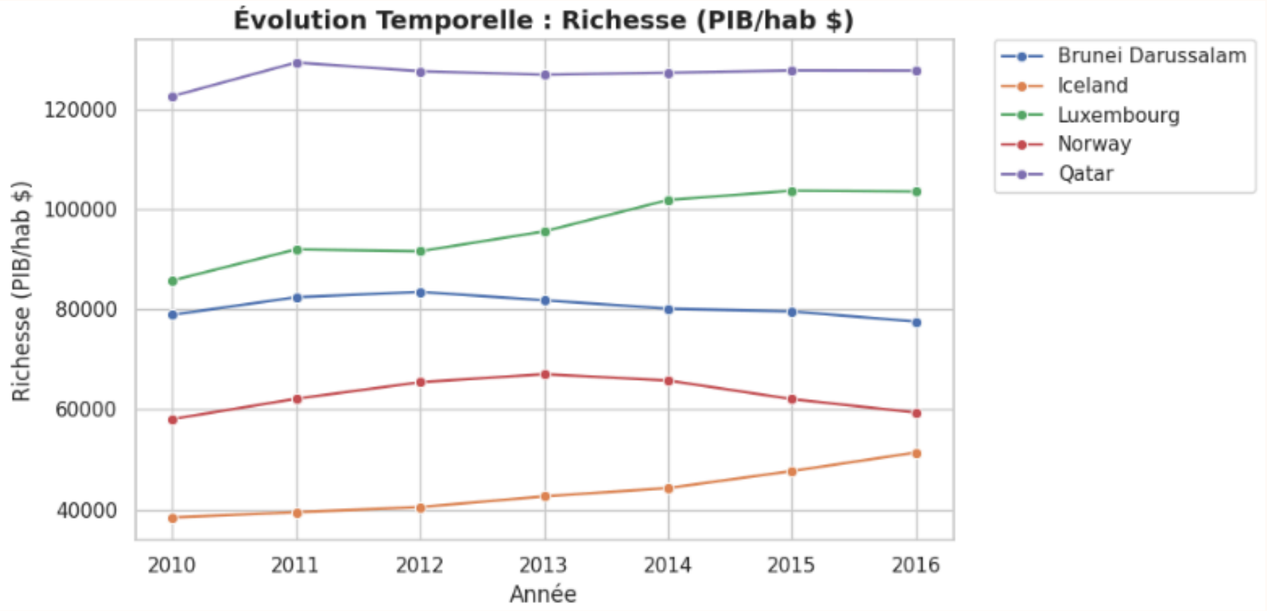


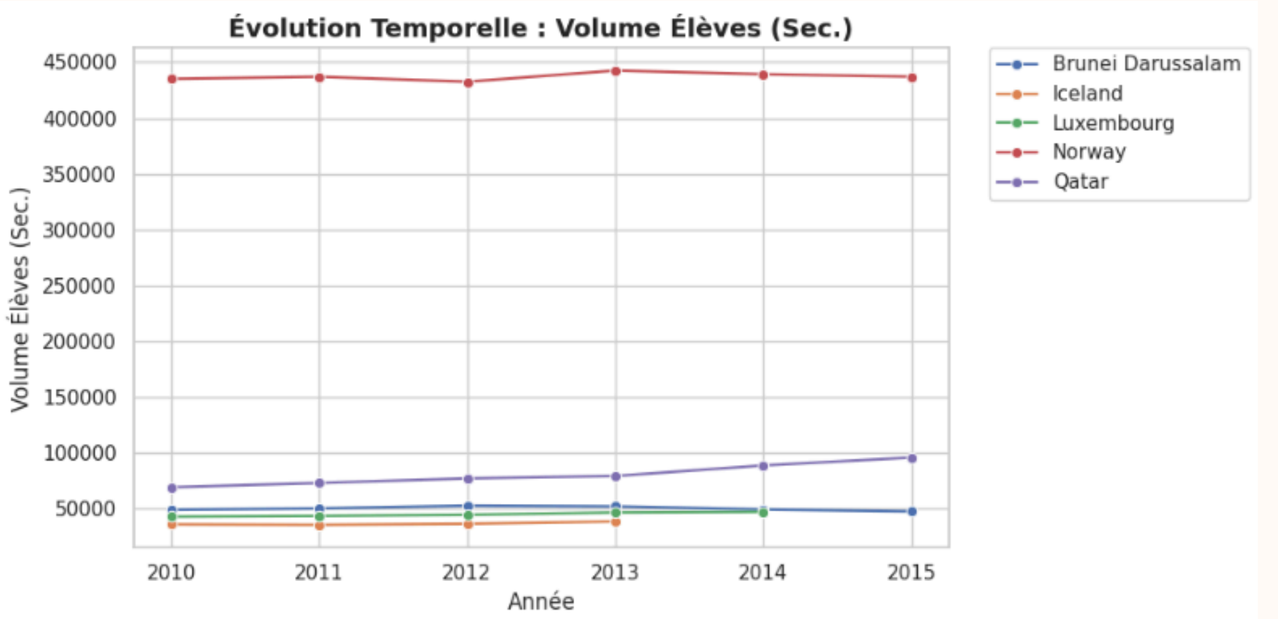


Time Series : Évolution 2010-2020 (Top 5)



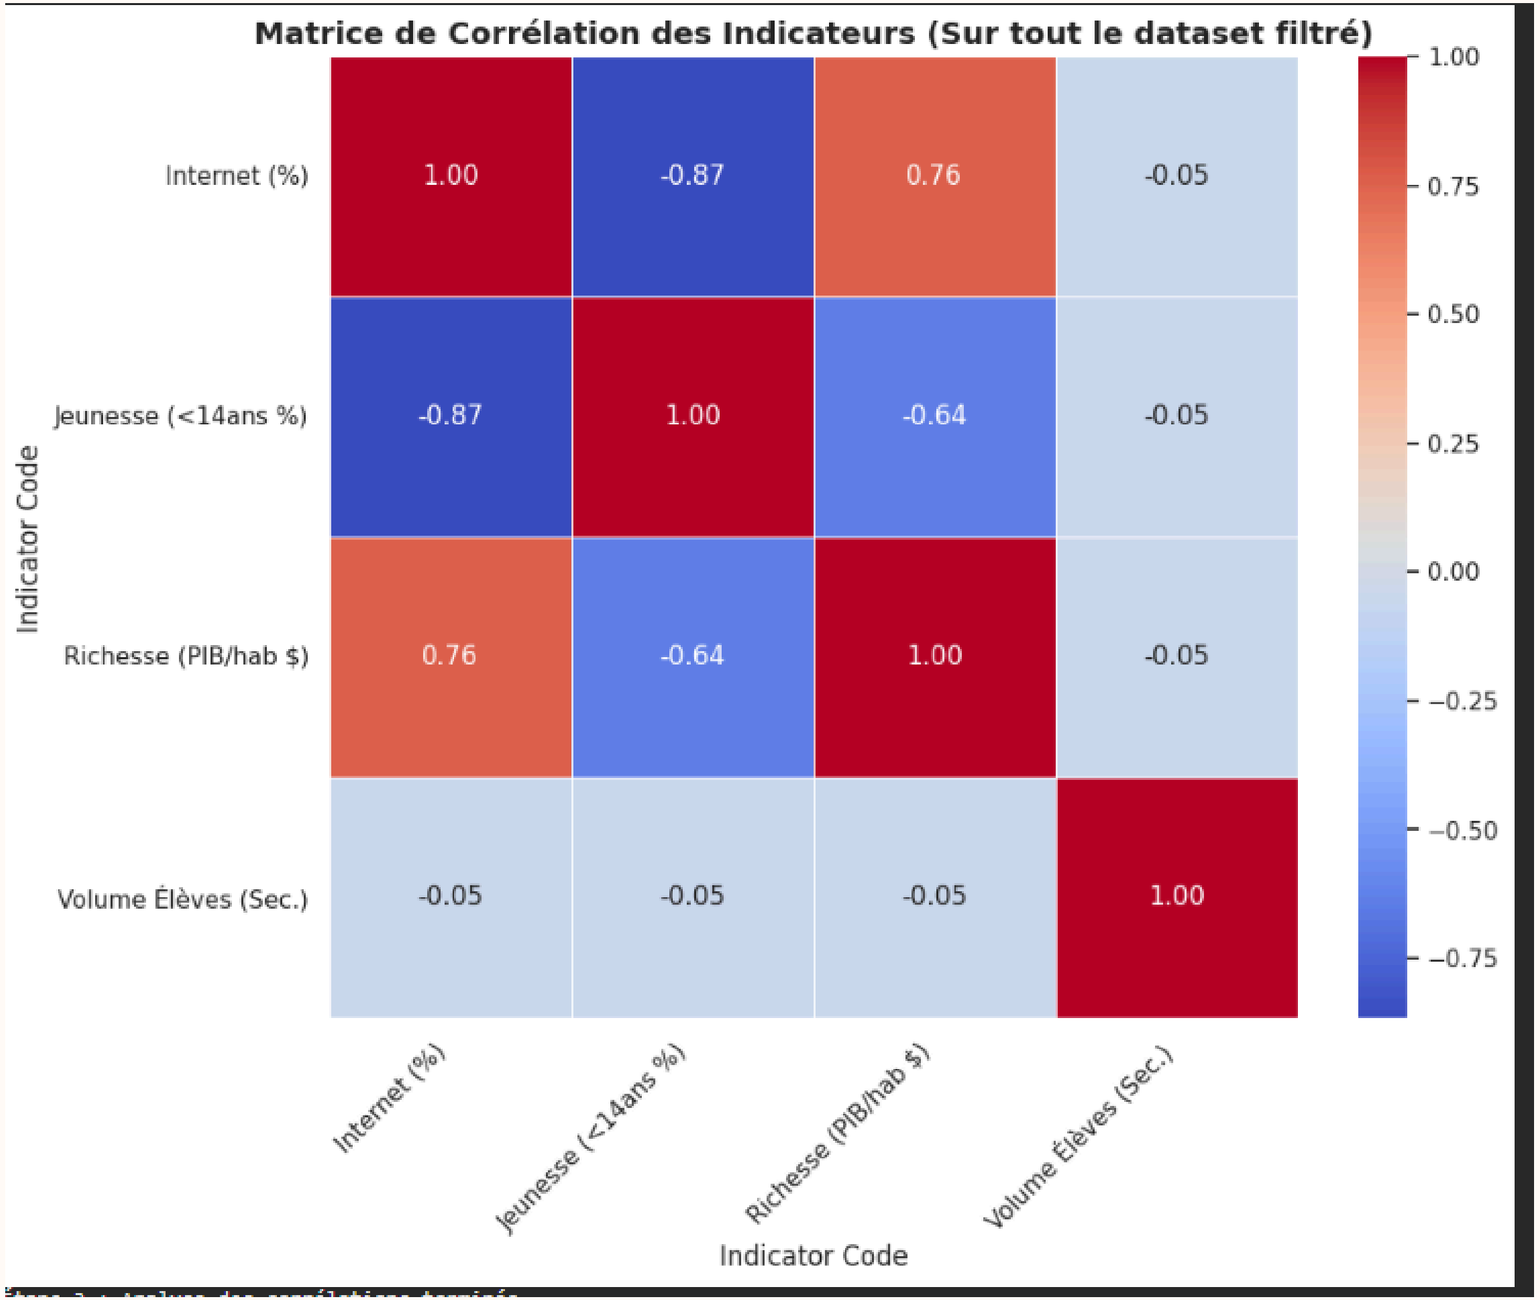






Heatmap corrélation :

Liens entre indicateurs
(ex: Richesse ↔ Internet)



🟥 Rouge (Proche de 1) :
Les indicateurs évoluent ensemble.

🟦 Bleu (Proche de -1) :
Les indicateurs s'opposent.

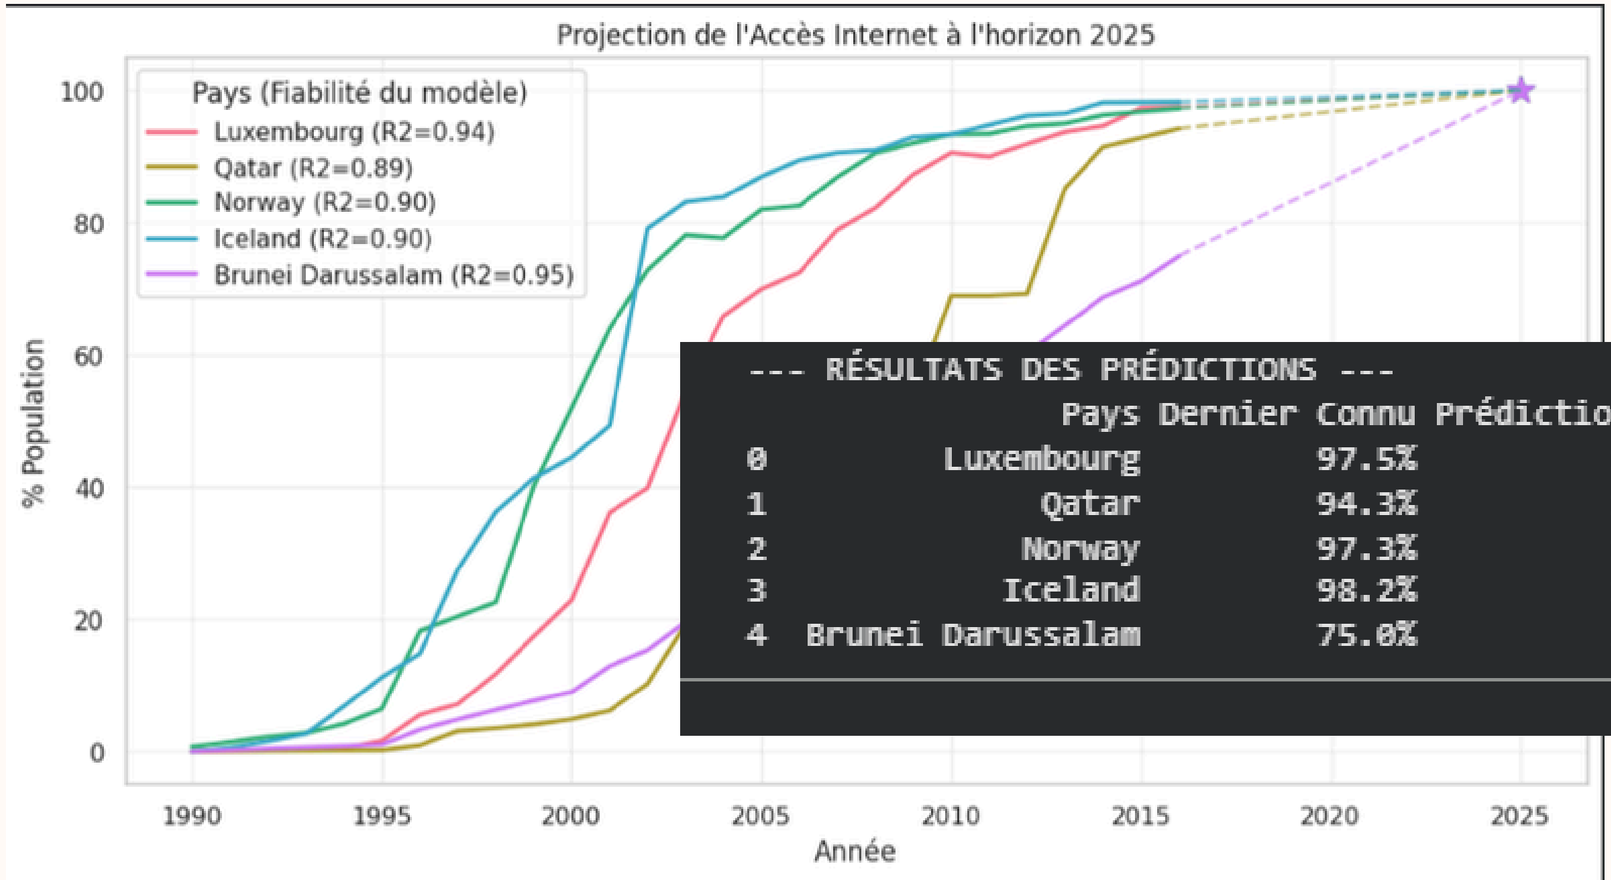
Prédiction du Potentiel

Contenu principal :

Modèle : Régression linéaire simple par pays/indicateur

Focus : Projection accès Internet à 2025 (Top 5)

Graphique : Historique + projection (lignes pointillées)
Tableau prédictions (beaucoup atteignent ~100%)




```
--- RÉSULTATS DES PRÉDICTIONS ---
                Pays Dernier Connu Prédiction 2025 Confiance (R2)
0         Luxembourg         97.5%          100.0%           0.94
1              Qatar         94.3%          100.0%           0.89
2             Norway         97.3%          100.0%           0.90
3            Iceland         98.2%          100.0%           0.90
4  Brunei Darussalam         75.0%          100.0%           0.95
```

Conclusion & Recommandations Stratégiques

Podium (Qualité/Attractivité) :

Luxembourg (0.48)	• Marché riche • Saturé
Qatar (0.47)	• Fort investissement
Norvège (0.45)	• Culture numérique.

Observation Stratégique :

Les **États-Unis** (7ème, Score 0.41)	• Représentent le meilleur compromis Score/Volume (24M d'élèves vs 44k pour le Luxembourg)

Rappel des limites

- **Limites :**

  Beaucoup de données manquantes
  (nécessité d'imputation forte ou suppression),
  indicateurs macro
  (ne reflètent pas les inégalités locales).

Merci pour votre attention !